

PERTEMUAN KE-3: ANALISIS DATA EKSPLORATORI DAN VISUALISASI DATA

A. TUJUAN

Setelah menempuh praktikum ini diharapkan mahasiswa mampu

1. memahami dasar-dasar analisis data eksploratori
2. melakukan analisis data eksploratori dengan menggunakan Python
3. melakukan visualisasi data dengan menggunakan menggunakan Python.

B. MATERI

Analisis Data Eksploratori

Analisis Data Eksploratori (*Exploratory Data Analysis* - EDA) adalah proses awal dalam analisis data yang bertujuan untuk memahami karakteristik, pola, dan hubungan dalam dataset sebelum melakukan pemodelan atau pengambilan keputusan. Analisis Data Eksploratori sangat penting dalam proses analisis data karena membantu dalam memahami dataset sebelum digunakan untuk pemodelan atau pengambilan keputusan. Beberapa alasan utama EDA penting untuk dilakukan adalah

a. Memahami Struktur Data

Sebelum melakukan analisis lebih lanjut, maka perlu memahami struktur dataset, termasuk jumlah baris dan kolom, tipe data, serta distribusi nilai. Hal ini membantu dalam mengetahui apakah data sudah siap digunakan dan mengidentifikasi kesalahan atau ketidaksesuaian dalam dataset. Python menyediakan alat untuk menampilkan tipe data dan jumlah non-null values yaitu `df.info()` dan menampilkan beberapa baris pertama dataset dengan menggunakan `df.head()`.

b. Menemukan Data yang Hilang (Missing Values) dan Data Duplikat

Data yang hilang dapat menyebabkan bias atau kesalahan dalam analisis, sehingga perlu ditangani dengan tepat. Python menyediakan alat untuk mengidentifikasi data yang hilang dan penanganannya. Strategi penanganan dilakukan sesuai jenis data, distribusi data serta banyak data yang hilang (menghapus, mengganti dengan median/mean, dll.). Python dapat menampilkan jumlah missing values di setiap kolom dengan perintah `int(df.isnull().sum())`.

c. Mendeteksi Outlier (Data Pencilan)

Outlier bisa memberikan informasi berharga atau justru menyebabkan distorsi pada hasil analisis. Dengan deteksi outlier maka dapat menemukan anomali dalam data yang perlu ditindaklanjuti dan menentukan apakah outlier harus dihapus atau tetap digunakan.

d. Menentukan Pola dan Hubungan Antar Variabel

EDA membantu mengungkap hubungan antara variabel dalam dataset, yang berguna dalam pembuatan model prediktif atau pengambilan keputusan bisnis. Korelasi antar variabel dapat membantu dalam pemilihan fitur yang relevan dan visualisasi hubungan antar variabel dapat membantu dalam interpretasi data.

e. Membantu Pemilihan Model yang Tepat

Pemahaman distribusi data dan pola hubungan antar variabel dapat digunakan untuk memilih model analitik yang paling sesuai. Data dengan distribusi normal cocok untuk model statistik tertentu. Data yang memiliki multikolinearitas tinggi perlu transformasi sebelum digunakan dalam machine learning.

Beberapa langkah-Langkah yang harus dilakukan dalam EDA antara lain.

a. Memahami Data

Pemahaman data dilakukan dengan pembacaan dataset, pemahaman struktur data, pemeriksaan nilai yang hilang dan duplikasi data. Pembacaan dataset dapat dilakukan dengan menggunakan Python (`pandas`) atau tools lain seperti Excel, SQL, atau Power BI.

Pemeriksaan struktur data dapat dilakukan dengan pemeriksaan jumlah baris, kolom, tipe data, dan contoh data dengan menggunakan `.info()` dan `.head()`. Pemeriksaan nilai yang hilang (Missing Values) dapat menggunakan `.isnull().sum()`. Identifikasi duplikasi dapat menggunakan perintah `.duplicated().sum()`.

b. Analisis Statistik Deskriptif

Statistik Ringkasan dilakukan dengan menggunakan `.describe()` yaitu untuk mendapatkan informasi seperti mean, median, min, max, dan standar deviasi. Distribusi Data dapat diketahui dengan menggunakan histogram atau boxplot untuk melihat distribusi setiap variabel.

c. Visualisasi Data

Visualisasi dapat dilakukan dengan menggunakan grafik. Misalnya, histogram digunakan untuk melihat distribusi numerik dari variabel. Boxplot digunakan untuk mengidentifikasi outlier dalam dataset. Scatter Plot digunakan untuk melihat hubungan antara dua variabel numerik. Heatmap digunakan untuk melihat korelasi antar variabel dengan `seaborn.heatmap()`.

d. Analisis Korelasi

Analisis korelasi dapat dilakukan dengan menggunakan metode korelasi (`.corr()`). Korelasi digunakan untuk melihat hubungan antar variabel. Jika ada hubungan kuat (positif atau negatif), bisa menjadi indikasi untuk analisis lebih lanjut.

e. Penanganan Data yang Bermasalah

Data bermasalah dapat disebabkan oleh beberapa hal, misalnya data hilang, data pencilan. Data hilang dapat dilakukan penghapusan atau pengisian missing Values. Pengisian data hilang bisa dilakukan dengan mean, median, atau metode lain. Penanganan Outlier dapat dilakukan dengan transformasi data atau filtering. Normalisasi atau Standarisasi Data jika dibutuhkan dalam pemodelan machine learning.

Visualisasi Data

Visualisasi data adalah teknik untuk menyajikan data dalam format gambar atau grafik. Ini memungkinkan para pemangku kepentingan dan pembuat keputusan untuk menganalisis data secara visual. Data dalam format grafis memungkinkan mereka untuk mengidentifikasi tren dan pola baru dengan mudah. Manfaat utama dari visualisasi data adalah menyederhanakan informasi kuantitatif yang kompleks, membantu menganalisis dan mengeksplorasi data besar dengan mudah, mengidentifikasi area yang perlu perhatian atau perbaikan, mengidentifikasi hubungan antara titik data dan variabel, dan mengeksplorasi pola baru dan mengungkapkan pola tersembunyi dalam data.

Tiga faktor utama yang menjadi pertimbangan untuk Visualisasi Data adalah kejelasan, ketepatan dan efisiensi. Kejelasan memastikan bahwa kumpulan data lengkap dan relevan. Ini memungkinkan ilmuwan data untuk menggunakan pola-pola baru yang dihasilkan dari data di tempat-tempat yang relevan. Akurasi memastikan penggunaan representasi grafis yang sesuai untuk menyampaikan pesan yang benar. Efisiensi menggunakan teknik visualisasi yang efisien yang menyoroti semua titik data.

Ada beberapa faktor dasar yang perlu diperhatikan sebelum memvisualisasikan data, antara lain: efek visual, sistem koordinat, jenis dan skala data, interpretasi informatif. Efek Visual mencakup penggunaan bentuk, warna, dan ukuran yang sesuai untuk mewakili data yang dianalisis. Sistem Koordinat membantu mengatur titik data dalam koordinat yang disediakan. Jenis dan Skala Data memilih jenis data seperti numerik atau kategorikal. Interpretasi Informatif membantu menciptakan visual dengan cara yang efektif dan mudah ditafsirkan menggunakan label, legenda judul, dan petunjuk.

Visualisasi data membantu menginterpretasikan hasil dengan data yang besar dan kompleks. Dengan bantuan bahasa pemrograman Python maka dapat melakukan visualisasi data

Python memiliki beberapa pustaka populer untuk visualisasi data, seperti Matplotlib, Seaborn, Pandas Plot dan Plotly. Matplotlib digunakan untuk visualisasi dasar, misalnya garis, batang, scatter, dan histogram, sedangkan Seaborn menyediakan visualisasi statistik yang lebih menarik dan lebih mudah digunakan. Pandas Plot merupakan fitur bawaan Pandas untuk plotting cepat, sedangkan Plotly digunakan untuk visualisasi interaktif. Berikut adalah beberapa jenis grafik yang dapat dibuat dengan menggunakan Matplotlib:

1. **Grafik Garis (Line Plot).** Grafik ini digunakan untuk menggambarkan hubungan antara dua variabel yang terhubung dengan garis. Biasanya digunakan untuk data yang bersifat kontinu, seperti perkembangan waktu atau tren.
2. **Grafik Batang (Bar Plot).** Grafik batang digunakan untuk membandingkan data kategori. Data kategori biasanya diletakkan di sumbu x, sedangkan nilai numerik pada sumbu y.
3. **Grafik Batang Horizontal (Horizontal Bar Plot).** Seperti grafik batang biasa, tetapi dengan batang yang digambar secara horizontal. Ini digunakan saat label kategori lebih panjang dan lebih mudah dibaca secara horizontal.

4. Grafik Sebar (Scatter Plot). Grafik ini digunakan untuk menggambarkan hubungan antara dua variabel kontinu. Titik-titik pada grafik menunjukkan data yang masing-masing berkorespondensi dengan nilai x dan y.
5. Histogram. Grafik ini digunakan untuk menunjukkan distribusi frekuensi data numerik. Histogram memecah data menjadi beberapa interval (bin) dan menghitung jumlah data dalam setiap bin.
6. Pie Chart. Grafik lingkaran ini digunakan untuk menunjukkan proporsi bagian dari keseluruhan. Setiap potongan mewakili proporsi tertentu dari data yang ada.
7. Box Plot (Box-and-Whisker Plot). Grafik ini digunakan untuk menggambarkan distribusi data berdasarkan kuartil dan menunjukkan adanya pencilan. Box plot sangat berguna untuk memahami sebaran data.
8. Area Plot. Grafik area mirip dengan grafik garis, tetapi area di bawah garis diwarnai untuk menunjukkan volume atau akumulasi nilai.
9. Heatmap. Grafik ini menggambarkan data dua dimensi menggunakan warna, yang dapat membantu dalam visualisasi hubungan atau intensitas data pada dua variabel yang berbeda.
10. Stem Plot. Grafik ini digunakan untuk menggambarkan data diskrit dengan menunjukkan batang yang menghubungkan titik data dengan sumbu x.
11. Error Bar Plot. Grafik ini digunakan untuk menggambarkan ketidakpastian dalam data dengan menunjukkan error bar di sekitar titik data.
12. Quiver Plot. Grafik ini digunakan untuk menggambarkan vektor dua dimensi yang menunjukkan arah dan kekuatan. Ini sangat berguna dalam memvisualisasikan medan vektor seperti angin atau arus.
13. 3D Plot. Matplotlib juga mendukung pembuatan grafik tiga dimensi (3D), seperti grafik garis 3D, grafik sebar 3D, dan permukaan 3D, yang dapat digunakan untuk visualisasi data lebih kompleks.

Contoh 3.1

Buka dataset heart_disease_uci.csv dan lakukan pemahaman data dan analisis deskriptif.

Jawaban

Kode Program 3.1. Program pemahaman data dan analisis deskriptif.

No	Kode Program
1	import pandas as pd
2	file_path = "heart_disease_uci.csv"
3	# Membaca dataset
4	df = pd.read_csv(file_path)
5	df.info()
6	df.head()
7	df.describe()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 300 entries, 0 to 299
Data columns (total 16 columns):
 #   Column        Non-Null Count  Dtype  
---  --
 0   id            300 non-null    int64  
 1   age           300 non-null    int64  
 2   sex           300 non-null    object  
 3   dataset       300 non-null    object  
 4   cp            300 non-null    object  
 5   trestbps      300 non-null    float64 
 6   chol          300 non-null    float64 
 7   fbs           300 non-null    object  
 8   restecg       300 non-null    object  
 9   thalach       300 non-null    float64 
10   exang         300 non-null    object  
11   oldpeak       300 non-null    float64 
12   slope         300 non-null    object  
13   ca            300 non-null    float64 
14   thal          300 non-null    object  
15   num           300 non-null    int64  
dtypes: float64(5), int64(3), object(8)
memory usage: 115+ KB
```

(a)

	id	age	sex	dataset	cp	trestbps	chol	fbs	restecg	thalch	exang	oldpeak	slope	ca	thal	num
0	1	63	Male	Cleveland	typical angina	145.0	233.0	True	lv hypertrophy	150.0	False	2.3	downsloping	0.0	fixed defect	0
1	2	67	Male	Cleveland	asymptomatic	160.0	286.0	False	lv hypertrophy	108.0	True	1.5	flat	3.0	normal	2
2	3	67	Male	Cleveland	asymptomatic	120.0	229.0	False	lv hypertrophy	129.0	True	2.6	flat	2.0	reversible defect	1
3	4	37	Male	Cleveland	non-anginal	130.0	250.0	False	normal	167.0	False	3.5	downsloping	6.0	normal	0
4	5	41	Female	Cleveland	atypical angina	130.0	264.0	False	lv hypertrophy	172.0	False	1.4	upsloping	0.0	normal	0

(b)

	id	age	trestbps	chol	thalch	oldpeak	ca	num
count	920.000000	920.000000	861.000000	886.000000	885.000000	858.000000	309.000000	920.000000
mean	450.500000	53.510870	132.132404	199.130337	137.545865	0.876788	0.676375	0.995652
std	265.725422	9.424895	19.086070	110.780010	25.928278	1.091226	0.935853	1.142693
min	1.000000	28.000000	0.000000	0.000000	60.000000	-2.500000	0.000000	0.000000
25%	230.750000	47.000000	120.000000	176.000000	120.000000	0.000000	0.000000	0.000000
50%	460.500000	54.000000	130.000000	223.000000	140.000000	0.000000	0.000000	1.000000
75%	690.250000	60.000000	140.000000	268.000000	157.000000	1.500000	1.000000	2.000000
max	920.000000	77.000000	200.000000	803.000000	202.000000	6.200000	3.000000	4.000000

(c)

Gambar 3.1. Contoh pemahaman data. (a) info data. (b) contoh 5 baris pertama data. (c) ringkasan statistik data.

Keluaran dari Kode Program 3.1. dapat dilihat pada Gambar 3.1

Gambar 3.1a menunjukkan info dari data. data memiliki 920 baris (dari indeks 0 hingga 919). Dataset memiliki 16 kolom, yang terdiri dari: 5 kolom bertipe float64 (bilangan desimal), 3 kolom bertipe int64 (bilangan bulat) dan 8 kolom bertipe object (biasanya teks atau kategori). Beberapa kolom memiliki nilai yang hilang (non-null count lebih kecil dari 920), seperti: trestbps (861 dari 920, jadi 59 data hilang) chol (30 data hilang), slope (309 data hilang), ca (611 data hilang, hampir 2/3 dari dataset) dan thal (486 data hilang, lebih dari setengah dataset). Setiap baris pada Gambar 3.1.1b merepresentasikan 1 pasien, dan setiap kolom berisi atribut kesehatan mereka. Deskripsi masing masing fitur atau variabel perlu dipahami sehingga dapat dilakukan indentifikasi nilai-nilai yang logis atau tidak logis dari data-data yang terisi.

Tabel 3.1. Deskripsi dataset

Kolom	Deskripsi
id	ID unik untuk setiap pasien
age	Usia pasien (tahun)
sex	Jenis kelamin pasien (Male atau Female)
dataset	Sumber dataset (Cleveland, dll.)
cp	Jenis nyeri dada (<i>chest pain type</i>): - typical angina: Nyeri dada khas - atypical angina: Nyeri dada tidak khas - non-anginal: Nyeri bukan karena angina - asymptomatic: Tanpa gejala
trestbps	Tekanan darah saat istirahat (mmHg)
chol	Kolesterol total dalam darah (mg/dL)
fbs	<i>Fasting Blood Sugar</i> > 120 mg/dL? (True/False)
restecg	Hasil elektrokardiografi saat istirahat: - normal: Normal - lv hypertrophy: Hipertrofi ventrikel kiri (pembesaran jantung)
thalch	Denyut jantung maksimum yang dicapai
exang	Nyeri dada akibat olahraga (True/False)
oldpeak	Depresi segmen ST setelah latihan (indikasi iskemia)
slope	Kemiringan segmen ST setelah latihan: - upsloping: Menanjak (normal) - flat: Datar (waspada) - downsloping: Menurun (berisiko tinggi)
ca	Jumlah pembuluh darah utama yang terlihat dalam fluoroskopi (0-3)
thal	Jenis kelainan aliran darah jantung: - normal: Normal - fixed defect: Cacat tetap - reversable defect: Cacat yang dapat diperbaiki

num	Diagnosis penyakit jantung (target): - 0: Tidak ada penyakit jantung - 1-4: Tingkat keparahan penyakit jantung
-----	--

Analisis singkat dapat dilakukan pada contoh data pada Gambar 3.1b. Kolom num adalah target (label) yang menunjukkan ada/tidaknya penyakit jantung. Pasien dengan num = 0 tidak memiliki penyakit jantung. Pasien dengan num > 0 memiliki tingkat keparahan penyakit.

Kolom cp (Chest Pain Type) penting karena asymptomatic lebih sering terkait penyakit jantung (num > 0) dan typical angina lebih sering tidak berisiko (num = 0). Kolom oldpeak & slope menunjukkan hubungan dengan iskemia jantung. Nilai oldpeak lebih tinggi dapat mengindikasikan risiko penyakit jantung. Downsloping cenderung lebih berisiko dibanding upsloping. Kolom ca dan thal memiliki banyak nilai yang hilang (perlu ditangani sebelum analisis lebih lanjut).

Dari analisis data tersebut, langkah selanjutnya dapat dilakukan pemeriksaan distribusi num.

Visualisasi hubungan antar variabel: misalnya, apakah tekanan darah (trestbps) dan kolesterol (chol) berkorelasi dengan num?, menangani nilai yang hilang di ca, thal, dan slope, mengubah variabel kategori (sex, cp, dll.) menjadi bentuk numerik agar bisa digunakan dalam model Machine Learning.

Gambar 3.1c menunjukkan ringkasan statistik dari setiap kolom numerik. Id merupakan Identifikasi pasien. Nilai mean = 460.5 menunjukkan nomor ID rata-rata. Nilai ini tidak berguna untuk analisis medis. Age menunjukkan Usia pasien (tahun). Rata-rata usia adalah 53.51 tahun. Usia termuda = 28 tahun, tertua = 77 tahun. Median (50%) = 54 tahun, menunjukkan banyak pasien berusia sekitar pertengahan 50-an. Trestbps adalah Tekanan darah istirahat dalam mmHg. Rata-rata Trestbps adalah 132.13 mmHg. Min = 0, yang mungkin adalah kesalahan data. Maks = 200, menunjukkan pasien dengan tekanan darah sangat tinggi. Banyak pasien memiliki tekanan darah di sekitar 130-140 mmHg (persentil 50% dan 75%).

chol menunjukkan kolesterol total dalam mg/dL. Rata-rata = 199.13 mg/dL, yang masih dalam batas normal. Min = 0, yang kemungkinan kesalahan data. Maks = 603 mg/dL, yang sangat tinggi. Sebagian besar pasien memiliki kolesterol antara 175 - 268 mg/dL. thalch menunjukkan denyut jantung maksimum yang dicapai saat Latihan. Rata-rata = 137.55 denyut/menit. Min = 60 denyut/menit, yang cukup rendah. Maks = 202 denyut/menit, yang sangat tinggi. Sebagian besar pasien memiliki denyut jantung sekitar 120-157 denyut/menit. oldpeak mendeskripsikan Depresi segmen ST setelah Latihan. Rata-rata = 0.88. Min = -2.6, yang tidak masuk akal (mungkin kesalahan data). Maks = 6.2, yang bisa menunjukkan iskemia parah. 50% pasien memiliki oldpeak sekitar 0.5, yang masih dalam batas aman.

ca mendeskripsikan jumlah pembuluh darah utama yang terlihat dalam fluoroskopi. Rata-rata = 0.68, menunjukkan sebagian besar pasien memiliki 0-1 pembuluh darah yang terlihat. Min = 0, Maks = 3. Banyak nilai yang hilang (hanya 309 dari 920 yang terisi).

num mewakili tingkat penyakit jantung atau target prediksi Mean = 0.99, menunjukkan mayoritas pasien memiliki tingkat penyakit ringan atau tidak ada penyakit. Min = 0 (tidak ada penyakit jantung). Max = 4 (penyakit jantung parah). 50% pasien memiliki nilai ≤ 1 , artinya banyak pasien tanpa penyakit atau dengan penyakit ringan.

Temuan penting dari ringkasan statistik dari dataset adalah beberapa kolom memiliki nilai aneh seperti $\text{trestbps} = 0$, $\text{chol} = 0$, $\text{oldpeak} = -2.6$. Mungkin ada kesalahan data, Kolom ca memiliki banyak data hilang, perlu penanganan sebelum digunakan, Banyak pasien memiliki num = 0, artinya dataset ini mungkin tidak seimbang (perlu dicek lebih lanjut) dan beberapa pasien memiliki kolesterol sangat tinggi (> 600), yang mungkin pasien dengan penyakit jantung parah.

Contoh 3.2

Buatlah Bar Chart mendapatkan distribusi data dari fitur num pada data heart_disease_uci.csv.

Jawaban

Kode Program 3.2. Program Bar Chart untuk menampilkan distribusi data dari fitur num.


No	Kode Program
1	<code>import pandas as pd</code>
2	<code>import matplotlib.pyplot as plt</code>
3	<code>file_path = "heart_disease_uci.csv"</code>
4	<code># Membaca dataset</code>
5	<code>df = pd.read_csv(file_path)</code>
6	<code>num_counts = df['num'].value_counts()</code>


```

7 plt.figure(figsize=(8, 6))
8 num_counts.plot(kind='bar', color='skyblue')
9 plt.title('Bar Chart of num Column')
10 plt.xlabel('num')
11 plt.ylabel('Frequency')
12 plt.xticks(rotation=0)
13 plt.show()

```

Keluaran dari Program 3.2 adalah



Gambar 3.2. Bar Chart untuk menampilkan distrbusi data dari fitur num


Gambar 3.2. menampilkan kelas data tidak berimbang sehingga perlu dipertimbangkan untuk menyeimbangkan kelas.

Contoh 3.3

Buatlah grafik Stacked Bar Plot untuk menampilkan hubungan antar fitur cp dan num pada data heart_disease_uci.csv.

Jawaban

Keluaran dari Program 3.3 adalah



Gambar 3.3. Grafik stacked bar plot untuk menampilkan hubungan antar fitur cp dan num.

Kode Program 3.3. Program untuk menggambar stacked bar plot untuk menampilkan hubungan antar fitur cp dan num.

No	Kode Program
1	import pandas as pd
2	import matplotlib.pyplot as plt
3	df = pd.read_csv("heart_disease_uci.csv")
4	# Membuat tabulasi silang antara 'cp' dan 'num'
5	cp_num_crosstab = pd.crosstab(df['cp'], df['num'])
6	# Membuat stacked bar plot
7	cp_num_crosstab.plot(kind='bar', stacked=True, figsize=(10, 6))
8	# Menambahkan judul dan label

```

9 plt.title('Stacked Bar Plot: Hubungan antara cp dan num', fontsize=16)
10 plt.xlabel('Kategori CP', fontsize=12)
11 plt.ylabel('Frekuensi', fontsize=12)
12 # Menambahkan legenda
13 plt.legend(title='Num (Penyakit Jantung)', loc='upper right')
14 # Menampilkan plot
15 plt.tight_layout()
16 plt.show()

```

Dari grafik batang bertumpu maka distribusi pasien dengan risiko penyakit jantung (num) berdasarkan kategori cp dapat dilihat. Jika grafik menunjukkan bahwa kategori cp tertentu memiliki proporsi yang lebih tinggi pada num = 4, ini dapat mengindikasikan bahwa jenis nyeri dada tersebut mungkin merupakan faktor risiko yang signifikan untuk penyakit jantung (asymptomatic dan non-anginal). Sebaliknya, jika kategori cp tertentu lebih dominan pada num = 0, ini mungkin menunjukkan bahwa jenis nyeri dada tersebut tidak terlalu berhubungan dengan risiko penyakit jantung yang tinggi.

C. TUGAS/LATIHAN SOAL

1. Apa distribusi nilai dari kolom age dan trestbps? Gambarkan menggunakan histogram.
2. Apa rentang nilai kolom chol dan thalch? Identifikasi apakah ada nilai ekstrim (outliers) dalam data ini.
3. Berapa banyak kategori yang ada dalam kolom cp (chest pain type)? Buat diagram batang untuk visualisasinya.
4. Kolom sex memiliki dua kategori (laki-laki dan perempuan). Bagaimana distribusi jumlah kasus berdasarkan jenis kelamin dalam dataset ini?
5. Apakah ada korelasi antara kolom-kolom numerik seperti age, trestbps, chol, thalch, oldpeak? Gunakan heatmap atau matriks korelasi untuk memvisualisasikan hubungan antar variabel.
6. Apakah terdapat hubungan antara usia (age) dan nilai tekanan darah (trestbps)? Buat scatter plot dan tentukan apakah ada pola tertentu.
7. Berapa banyak data yang hilang (missing values) dalam setiap kolom? Tentukan apakah ada pola tertentu dalam data yang hilang.
8. Apakah ada nilai ekstrem (outliers) dalam kolom age, chol, atau oldpeak? Gunakan boxplot untuk mengidentifikasi outliers.
9. Jika ada outliers pada kolom numerik, apakah pengaruhnya terhadap analisis data? Bagaimana cara Anda menangani outliers ini?
10. Bagaimana distribusi nilai num (diagnosis penyakit jantung) dalam dataset? Tampilkan dengan diagram batang atau pie chart.
11. Apa hubungan antara num (0-4) dan kolom age, trestbps, chol, thalch, atau kolom numerik lainnya? Buat boxplot untuk melihat distribusi masing-masing fitur berdasarkan nilai num.
12. Apakah ada perbedaan signifikan dalam nilai chol berdasarkan kategori cp (tipe nyeri dada)? Gunakan boxplot atau histogram untuk membandingkan distribusi nilai chol.
13. Apakah terdapat perbedaan yang signifikan dalam usia (age) berdasarkan jenis kelamin (sex) dan nilai num (diagnosis penyakit jantung)? Visualisasikan dengan scatter plot atau boxplot.
14. Berdasarkan EDA yang telah dilakukan, faktor-faktor apakah yang paling berhubungan dengan diagnosis penyakit jantung (num)? Berikan analisis singkat.