





Gambar 5.2. Grafik hubungan support dan Lift



Gambar 4.3. Grafik hubungan Confidence Lift

C. TUGAS/LATIHAN SOAL

1. Buatlah program untuk menghitung support dari suatu himpunan transaksi dengan kardinal items set satu.
2. Buatlah program untuk menghitung support dari suatu himpunan transaksi yang memenuhi minimum support yang diberikan.

PERTEMUAN KE-6: METODE K-MEANS

A. TUJUAN


Setelah menempuh praktikum ini diharapkan mahasiswa mampu

1. memahami menjelaskan cara kerja dari metode K-means.
2. membuat program metode K-means dengan menggunakan Bahasa Pemrograman Python.
3. menggunakan metode K-means untuk analisis *cluster*.

B. MATERI

Clustering adalah metode penganalisaan data, yang sering dimasukkan sebagai salah satu metode *data mining*. *Clustering* merupakan sebuah proses mengelompokkan data ke dalam beberapa kluster atau kelompok sehingga data dalam satu kluster memiliki tingkat kemiripan setinggi mungkin dan data antar kluster memiliki tingkat kemiripan serendah mungkin. Tujuannya dari *clustering* adalah untuk mengelompokkan data dengan karakteristik yang sama ke suatu kelompok yang sama dan data dengan karakteristik yang berbeda ke kelompok yang lain. Ada beberapa pendekatan yang digunakan dalam metode *clustering*. Dua pendekatan utama adalah *clustering* dengan pendekatan partisi dan *clustering* dengan pendekatan hirarki. *Clustering* dengan pendekatan partisi atau sering disebut dengan *partition-based clustering* mengelompokkan data dengan memilah-milah data yang dianalisa ke dalam cluster-cluster yang ada. *Clustering* dengan pendekatan hirarki atau sering disebut dengan *hierarchical clustering* mengelompokkan data dengan membuat suatu hirarki berupa dendogram dimana data yang mirip akan ditempatkan pada hirarki yang berdekatan dan yang tidak pada hirarki yang berjauhan.

K-Means adalah suatu metode penganalisaan data atau metode data mining yang melakukan proses pemodelan tanpa supervisi (*unsupervised*) dan merupakan salah satu metode yang melakukan pengelompokan data dengan pendekatan partisi. Metode k-means berusaha mengelompokkan data yang ada ke dalam beberapa kelompok, dimana data dalam satu kelompok mempunyai karakteristik yang sama satu sama lainnya dan mempunyai karakteristik yang berbeda dengan data yang ada di dalam kelompok yang lain. Dengan kata lain, metode ini berusaha untuk meminimalkan variasi antar data yang ada di dalam suatu cluster dan memaksimalkan variasi dengan data yang ada di cluster lainnya. Proses clustering menggunakan K-means clustering dapat dilihat pada Gambar 6.1.



Gambar 6.1 Proses clustering dengan K-means clustering.

Terdapat n titik data yang dilambangkan dengan titik berwarna hitam dan titik $\times$ berwarna biru, merah, dan hijau yang merupakan pusat kluster awal. Titik data tersebut akan dikelompokkan menjadi 3 kluster, yaitu biru, merah, dan hijau. Pengelompokan tersebut dilakukan dengan cara menghitung jarak antara titik data dengan masing-masing pusat kluster. Setiap titik data akan dikelompokkan ke kluster yang memiliki jarak paling minimum antara data dengan setiap pusat kluster sehingga setiap kluster akan memiliki anggota. Kemudian dihitung kembali pusat kluster yang baru dengan cara menghitung rata-rata nilai anggota setiap kluster. Seiring dengan iterasi, anggota tiap kluster akan memiliki karakteristik yang identik dan algoritma K-means clustering sudah konvergen dapat dilihat pada Gambar 6.1.

Terdapat proses optimasi pada algoritma K-means clustering, yaitu meminimumkan jarak setiap titik data ke pusat klasternya. Algoritma K-means clustering adalah sebagai berikut.

1. Diberikan Himpunan Data

Misalkan kita memiliki himpunan data X yang terdiri dari beberapa titik dalam ruang fitur:

$$X = \{x_1, x_2, x_3, \dots, x_n\}$$

di mana setiap x_i adalah vektor dalam dimensi MMM :

$$x_i = (x_{i1}, x_{i2}, \dots, x_{iM})$$

2. Inisialisasi Himpunan Pusat Cluster

- Memilih k pusat cluster awal secara acak:

$$C = \{C_1, C_2, \dots, C_k\}$$

dengan setiap pusat cluster C_j sebagai vektor dalam dimensi M :

$$C_j = (C_{j1}, C_{j2}, \dots, C_{jM})$$

3. Menentukan Himpunan Cluster

Setiap titik x_i dimasukkan ke dalam cluster berdasarkan kedekatan dengan centroid C_j . Maka, setiap cluster S_j berisi titik-titik terdekat dengan centroid tersebut:

$$S_j = \{x_i \mid d(x_i, C_j) \leq d(x_i, C_m), \forall m \neq j\}$$

di mana $d(x_i, C_j)$ adalah fungsi jarak (biasanya jarak Euclidean):

$$d(x_i, C_j) = \sqrt{\sum_{m=1}^M (x_{im} - C_{jm})^2}$$

4. Mengupdate Himpunan Pusat Cluster

Setelah data dikelompokkan, pusat cluster diperbarui dengan menghitung rata-rata dari titik-titik dalam cluster:

$$C_j = \frac{1}{|S_j|} \sum_{\{x_i \in S_j\}} x_i$$

di mana:

- S_j adalah himpunan titik dalam cluster j ,
- $|S_j|$ adalah jumlah elemen dalam cluster j .

Himpunan pusat cluster yang diperbarui:

$$C = \{C'_1, C'_2, \dots, C'_k\}$$

5. Mengulangi Langkah 3 dan 4 Hingga Konvergen

Proses terus diulang sampai pusat cluster **tidak berubah lagi** atau perubahan sangat kecil:

$$C^{t+1} = C^t$$

Maka, hasil akhir adalah **himpunan cluster final**:

$$S = \{S_1, S_2, \dots, S_k\}$$

dengan **himpunan pusat cluster final**:

$$C = \{C^*_1, C^*_2, \dots, C^*_k\}$$

Algoritma *K-means clustering* merupakan algoritma *clustering* yang paling sederhana, mudah dimengerti, dan banyak digunakan dalam masalah pengelompokan data. Hal ini dikarenakan *K-means clustering* mampu mengelompokkan data dalam jumlah yang cukup besar dengan waktu komputasi yang singkat. Algoritma *K-means clustering* juga memiliki daya eksploitasi yang kuat, karena mampu memusatkan pencarian di sekitar area yang dianggap optimum. Dengan kata lain, *K-means clustering* sangat cocok untuk menentukan solusi optimum lokal. Namun *K-means clustering* juga memiliki beberapa kekurangan, yaitu:

- Jumlah klaster (k) yang ditentukan sebelumnya. Nilai k harus ditentukan ketika algoritma diinisialisasi. Tetapi dalam beberapa kasus, sulit untuk menentukan secara akurat nilai k yang paling sesuai.
- Algoritma *K-means clustering* sangat sensitif terhadap pusat klaster awal. Pusat klaster awal yang tidak tepat akan menghasilkan *output clustering* yang tidak tepat juga, sehingga dapat menyebabkan algoritma terperangkap di sekitar nilai optimum lokal.
- Cepat konvergen ke optimum lokal. *K-means clustering* memiliki daya eksplorasi yang terbilang lemah, karena kurang mampu melakukan pencarian di seluruh daerah solusi untuk mendapatkan nilai optimum. Hal ini menyebabkan *output clustering* terperangkap di sekitar nilai optimum lokal sehingga objek hasil *clustering* yang diperoleh pun akan tidak sesuai dengan semestinya.

Contoh 6.1


Buatlah program dari algoritma k-means dengan Bahasa Pemrograman Python

Jawaban

Kode Program 6.1. Program metode k-means.

No	Kode Program
1	import numpy as np
2	import matplotlib.pyplot as plt
3	def euclidean_distance(x1, x2):
4	return np.sqrt(np.sum((x1 - x2) ** 2))
5	def k_means(X, k, max_iters=100, tol=1e-4):
6	# Inisialisasi pusat cluster secara acak
7	np.random.seed(42)
8	centroids = X[np.random.choice(len(X), k, replace=False)]
9	for _ in range(max_iters):
10	# Membentuk himpunan cluster
11	clusters = {i: [] for i in range(k)}
12	for x in X:
13	distances = [euclidean_distance(x, centroid) for centroid in
14	centroids]
15	cluster_idx = np.argmin(distances)
16	clusters[cluster_idx].append(x)
17	# Menghitung pusat cluster baru
18	new_centroids = np.array([np.mean(clusters[i], axis=0) for i in
19	range(k)])
20	# Mengecek konvergensi
21	if np.linalg.norm(new_centroids - centroids) < tol:
22	break
23	centroids = new_centroids
24	return clusters, centroids
25	# Contoh data (himpunan titik)
26	X = np.array([
27	[2, 3], [3, 4], [5, 6], [8, 8], [9, 10],
28	[1, 2], [4, 5], [6, 7], [7, 9], [10, 11]
29	])
30	# Visualisasi awal data
31	plt.scatter(X[:, 0], X[:, 1], c='gray', marker='o', label='Data')
32	plt.title("Visualisasi Awal Data")
33	plt.xlabel("Fitur 1")
34	plt.ylabel("Fitur 2")
35	plt.legend()
36	plt.show()
37	# Menjalankan algoritma K-Means dengan k=2
38	k = 2
39	clusters, centroids = k_means(X, k)
40	# Menampilkan hasil
41	print("Himpunan Cluster:")
42	for i, cluster in clusters.items():
43	print(f"S_{i+1} = {np.array(cluster)}")
44	print("\nHimpunan Pusat Cluster Akhir:")
45	print(centroids)
46	# Visualisasi hasil clustering
47	colors = ['r', 'b', 'g', 'y', 'c']
48	plt.figure(figsize=(8, 6))
49	for i, cluster in clusters.items():
50	cluster_points = np.array(cluster)
51	plt.scatter(cluster_points[:, 0], cluster_points[:, 1], c=colors[i],
52	label=f'Cluster {i+1}')
53	plt.scatter(centroids[:, 0], centroids[:, 1], c='black', marker='X',
54	s=200, label='Centroid')
55	plt.title("Hasil Clustering K-Means")
56	plt.xlabel("Fitur 1")
57	plt.ylabel("Fitur 2")
58	plt.legend()
59	plt.show()

Hasil dari Kode Program



Gambar 6.1. Plot data sebelum dan setelah dikelompokkan

Himpunan Cluster:

$S_1 = \begin{bmatrix} 8 & 8 \\ 9 & 10 \\ 6 & 7 \\ 7 & 9 \\ 10 & 11 \end{bmatrix}$

$S_2 = \begin{bmatrix} 2 & 3 \\ 3 & 4 \\ 5 & 6 \\ 1 & 2 \\ 4 & 5 \end{bmatrix}$

Himpunan Pusat Cluster Akhir:

$\begin{bmatrix} 8.9 \\ 3.4 \end{bmatrix}$

Contoh 6.2

Gunakan metode K-means untuk pelanggan dari data yang diberikan / Mall_Customers.csv.

Jawaban

Kode Program 6.2. Program metode k-means untuk pengelompokan pelanggan dari data yang diberikan / Mall_Customers.csv

No	Kode Program
1	<code>import numpy as np</code>
2	<code>import matplotlib.pyplot as plt</code>
3	<code>import pandas as pd</code>
4	<code>def euclidean_distance(x1, x2):</code>
5	<code> return np.sqrt(np.sum((x1 - x2) ** 2))</code>
6	<code>def k_means(X, k, max_iters=100, tol=1e-4):</code>
7	<code> # Inisialisasi pusat cluster secara acak</code>
8	<code> np.random.seed(42)</code>
9	<code> centroids = X[np.random.choice(len(X), k, replace=False)]</code>
10	<code> for _ in range(max_iters):</code>
11	<code> # Membentuk himpunan cluster</code>
12	<code> clusters = {i: [] for i in range(k)}</code>
13	<code> for x in X:</code>
14	<code> distances = [euclidean_distance(x, centroid) for centroid in</code>
15	<code>centroids]</code>
16	<code> cluster_idx = np.argmin(distances)</code>
17	<code> clusters[cluster_idx].append(x)</code>
18	<code> # Menghitung pusat cluster baru</code>
19	<code> new_centroids = np.array([np.mean(clusters[i], axis=0) for i in</code>
20	<code>range(k)])</code>
21	<code> # Mengecek konvergensi</code>
22	<code> if np.linalg.norm(new_centroids - centroids) < tol:</code>


```

23         break
24         centroids = new_centroids
25     return clusters, centroids
26 # Data pelanggan (CustomerID, Gender, Age, Annual Income, Spending Score)
27 df = pd.read_csv("Mall_Customers.csv")
28 # Menggunakan fitur "Annual Income" dan "Spending Score" untuk clustering
29 X = df[["Annual Income (k$)", "Spending Score (1-100)"]].values
30 # Visualisasi awal data
31 plt.scatter(X[:, 0], X[:, 1], c='gray', marker='o', label='Data')
32 plt.title("Visualisasi Awal Data Pelanggan")
33 plt.xlabel("Annual Income (k$)")
34 plt.ylabel("Spending Score (1-100)")
35 plt.legend()
36 plt.show()
37 # Menjalankan algoritma K-Means dengan k=2
38 k = 2
39 clusters, centroids = k_means(X, k)
40 print("\nHimpunan Pusat Cluster Akhir:")
41 print(centroids)
42 # Visualisasi hasil clustering
43 colors = ['r', 'b', 'g', 'y', 'c']
44 plt.figure(figsize=(8, 6))
45 for i, cluster in clusters.items():
46     cluster_points = np.array(cluster)
47     plt.scatter(cluster_points[:, 0], cluster_points[:, 1], c=colors[i],
48 label=f'Cluster {i+1}')
49 plt.scatter(centroids[:, 0], centroids[:, 1], c='black', marker='X',
50 s=200, label='Centroid')
51 plt.title("Hasil Clustering K-Means")
52 plt.xlabel("Annual Income (k$)")
53 plt.ylabel("Spending Score (1-100)")
54 plt.legend()
55 plt.show()


```

Keluaran dari Kode Program 6.2. adalah

Himpunan Pusat Cluster Akhir:

[[79.6 50.12727273]

[37.28888889 50.28888889]]



Gambar 6.2. Plot data sebelum dan setelah dikelompokkan untuk data pelanggan

Contoh 6.2

Gunakan metode K-means untuk pelanggan dari data yang diberikan / Mall_Customers.csv dan tentukan jumlah cluster yang optimal dengan metode elbow.

Jawaban


Kode Program 6.2. Program metode k-means untuk pengelompokan pelanggan dari data yang diberikan / Mall_Customers.csv dan menentukan jumlah cluster yang optimal dengan metode elbow.

No	Kode Program
1	import numpy as np
2	import matplotlib.pyplot as plt
3	import pandas as pd
4	from sklearn.cluster import KMeans
5	def euclidean_distance(x1, x2):
6	return np.sqrt(np.sum((x1 - x2) ** 2))
7	def k_means(X, k, max_iters=100, tol=1e-4):
8	# Inisialisasi pusat cluster secara acak
9	np.random.seed(42)
10	centroids = X[np.random.choice(len(X), k, replace=False)]
11	for _ in range(max_iters):
12	# Membentuk himpunan cluster
13	clusters = {i: [] for i in range(k)}
14	for x in X:
15	distances = [euclidean_distance(x, centroid) for centroid in
16	centroids]
17	cluster_idx = np.argmin(distances)
18	clusters[cluster_idx].append(x)
19	# Menghitung pusat cluster baru
20	new_centroids = np.array([np.mean(clusters[i], axis=0) for i in
21	range(k)])
22	
23	# Mengecek konvergensi
24	if np.linalg.norm(new_centroids - centroids) < tol:
25	break
26	centroids = new_centroids
27	return clusters, centroids
28	# Data pelanggan (CustomerID, Gender, Age, Annual Income, Spending Score)
29	df = pd.read_csv("Mall_Customers.csv")
30	
31	# Menggunakan fitur "Annual Income" dan "Spending Score" untuk clustering
32	X = df[["Annual Income (k\$)", "Spending Score (1-100)"]].values
33	# Metode Elbow untuk Menentukan Jumlah Cluster Optimal
34	wcss = []
35	k_values = range(1, 6)
36	for k in k_values:
37	kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
38	kmeans.fit(X)
39	wcss.append(kmeans.inertia_)
40	# Plot hasil metode Elbow
41	plt.figure(figsize=(8, 5))
42	plt.plot(k_values, wcss, marker='o', linestyle='--')
43	plt.xlabel("Jumlah Cluster (k)")
44	plt.ylabel("Within-Cluster Sum of Squares (WCSS)")
45	plt.title("Metode Elbow untuk Menentukan k Optimal")
46	plt.show()
47	# Menjalankan algoritma K-Means dengan k=3 berdasarkan analisis Elbow
48	k = 3
49	clusters, centroids = k_means(X, k)
50	# Menampilkan hasil
51	print("Himpunan Cluster:")
52	for i, cluster in clusters.items():
53	print(f"S_{i+1} = {np.array(cluster)}")
54	print("\nHimpunan Pusat Cluster Akhir:")
55	print(centroids)
56	# Visualisasi hasil clustering
57	colors = ['r', 'b', 'g', 'y', 'c']
58	plt.figure(figsize=(8, 6))
59	for i, cluster in clusters.items():
60	cluster_points = np.array(cluster)


```

61 plt.scatter(cluster_points[:, 0], cluster_points[:, 1], c=colors[i],
62 label=f'Cluster {i+1}')
63 plt.scatter(centroids[:, 0], centroids[:, 1], c='black', marker='X',
64 s=200, label='Centroid')
65 plt.title("Hasil Clustering K-Means")
66 plt.xlabel("Annual Income (k$)")
67 plt.ylabel("Spending Score (1-100)")
68 plt.legend()
69 plt.show()

```



Gambar 6.2. Plot data sebelum dan setelah dikelompokkan untuk data pelanggan setelah ditentukan k yang tepat dengan metode elbow.

Berdasarkan hasil clustering K-Means dengan 5 cluster, berikut adalah analisisnya:

Cluster 1 (Merah) adalah pelanggan dengan pendapatan menengah (~40-60k\$) dan spending score tinggi (~50-70). Kemungkinan adalah pelanggan setia yang sering melakukan pembelian. Cluster 2 (Biru) adalah pelanggan dengan pendapatan rendah (~20-40k\$) tetapi spending score tinggi (~70-100). Mungkin merupakan pelanggan impulsif yang memiliki kebiasaan belanja tinggi meskipun pendapatannya lebih kecil. Cluster 3 (Hijau) adalah pelanggan dengan pendapatan rendah (~20-40k\$) dan spending score rendah (~0-40). Bisa jadi pelanggan yang hemat atau kurang tertarik berbelanja. Cluster 4 (Kuning) adalah Pelanggan dengan pendapatan tinggi (~80-120k\$) dan spending score tinggi (~60-100). Mereka bisa jadi adalah pelanggan premium atau VIP yang banyak berbelanja. Cluster 5 (Cyan) adalah pelanggan dengan pendapatan tinggi (~80-120k\$) tetapi spending score rendah (~0-40). Mungkin merupakan pelanggan kaya yang jarang berbelanja atau hanya membeli kebutuhan pokok. Pusat Cluster (Centroid) ditandai dengan tanda silang hitam (X). Setiap centroid menunjukkan pusat dari masing-masing kelompok pelanggan berdasarkan pendapatan tahunan dan tingkat pengeluaran mereka. Pola distribusi centroid menunjukkan adanya 5 segmen pelanggan yang jelas. Cluster 1 & 4 (Pelanggan Potensial) bisa diberikan promosi eksklusif atau program loyalitas untuk meningkatkan pembelian mereka. Cluster 2 (Pelanggan Impulsif) dapat diberikan diskon dan penawaran menarik agar mereka tetap aktif berbelanja. Cluster 3 & 5 (Pelanggan Pasif) perlu strategi khusus, seperti iklan bertarget atau penawaran berbasis kebutuhan, untuk meningkatkan engagement mereka.

C. TUGAS/LATIHAN SOAL

1. Modifikasi algoritma k-means dengan mengganti jarak Euclid dengan jarak Mahalanobis. Terapkan pada data Mall Customer. Bandingkan hasil clustering dengan menggunakan Jarak Mahalanobis dan Jarak Euclidean dan berikan analisis hasilnya.
2. Modifikasi algoritma k-means dengan mengganti jarak Euclid dengan jarak Mahattan. Terapkan pada data Mall Customer. Bandingkan hasil clustering dengan menggunakan Jarak Mahalanobis, Jarak Mahattan dan Jarak Euclidean dan berikan analisis hasilnya.