

PERTEMUAN KE-8: METODE CLUSTERING HIERARKI

A. TUJUAN

Setelah menempuh praktikum ini diharapkan mahasiswa mampu

1. menjelaskan cara kerja dari metode Clustering Hierarki
2. membuat program metode Clustering Hierarki dengan menggunakan Bahasa Pemrograman Python.
3. Menggunakan metode Clustering Hierarki untuk analisis cluster.

B. MATERI

Hierarki adalah analisis yang pengklasteran datanya dilakukan dengan cara mengukur jarak kedekatan pada setiap objek yang kemudian membentuk sebuah dendrogram. Jenis analisis klaster dengan metode hierarki ada beberapa macam metode. Metode hierarki memulai pengelompokkan dengan dua atau lebih objek yang mempunyai kesamaan paling dekat. Kemudian diteruskan pada obyek yang lain dan seterusnya hingga klaster akan membentuk semacam pohon dimana terdapat tingkatan (hierarki) yang jelas antara objek, dari yang paling mirip hingga yang paling tidak mirip. Alat yang membantu untuk memperjelas proses hierarki ini disebut dendrogram (Richard & kk, 2014).

Menurut (Handoyo, 2014) metode-metode yang bisa digunakan dalam metode hierarki adalah metode agglomeratif (*agglomerative method*) dan metode defisif (*devisive method*). Menurut (W.Hardle, 2007) metode agglomeratif dimulai dengan menganggap bahwa setiap objek adalah sebuah klaster. Kemudian dua objek dengan jarak terdekat digabungkan menjadi satu klaster. Selanjutnya obyek ketiga akan bergabung dengan klaster yang ada atau bersama objek lain dan membentuk klaster baru dengan tetap memperhitungkan jarak kedekatan antar obyek. Proses akan berlanjut hingga akhirnya terbentuk satu klaster yang terdiri dari keseluruhan objek.

Metode hierarki agglomeratif (*agglomerative method*) masih ada lima metode dalam pembentukan klaster yaitu:

1. Average Linkage yaitu menghitung jarak dua klaster yang disebut sebagai jarak rata-rata yang mana jarak tersebut dihitung pada masing-masing klaster.
2. Single Linkage yaitu similaritas dari dua klaster didasarkan pada dua titik paling dekat dari dua klaster yang berbeda. hal ini terus dilakukan hingga semua objek membentuk satu klaster.
3. Complete Linkage yaitu jarak antara dua buah klaster dihitung dari jarak terjauh antara anggota klaster satu dengan klaster kedua.
4. Ward's Method yaitu jarak antara dua klaster dalam metode ini berdasarkan total sum of square dua klaster pada masing-masing variable.
5. Metode Centroid yaitu jarak antara dua klaster dalam metode ini berdasarkan jarak centroid dua klaster yang bersangkutan

Strategi pengelompokannya umumnya ada 2 jenis yaitu *Agglomerative* (Bottom-Up) dan *Devisive* (Top-Down). Langkah Algoritma Agglomerative Hierarchical Clustering adalah

1. Hitung Matrik Jarak antar data.
2. Gabungkan dua kelompok terdekat berdasarkan parameter kedekatan yang ditentukan.
3. Perbarui Matrik Jarak antar data untuk merepresentasikan kedekatan diantara kelompok baru dan kelompok yang masih tersisa.
4. Ulangi langkah 2 dan 3 hingga hanya satu kelompok yang tersisa.

Contoh 8.1.

ID	X	Y
A	1	2
B	2	3
C	3	6
D	5	8

E	8	8
---	---	---

Langkah 1: Hitung Matriks Jarak Manhattan

Menghitung jarak antara semua pasangan titik menggunakan rumus:

$$d_{\text{Manhattan}}(A, B) = |x_1 - x_2| + |y_1 - y_2|$$

Matriks jarak hasil perhitungan manual:

	A	B	C	D	E
A	0	2	6	10	13
B	2	0	4	8	11
C	2	6	0	4	7
D	10	8	4	0	3
E	13	11	7	3	0

Langkah 2: Proses Penggabungan Cluster

Pada AHC, setiap titik data awalnya dianggap sebagai cluster sendiri-sendiri. Kemudian, kita menggabungkan dua cluster dengan jarak terkecil, lalu terus mengulang sampai semua data berada dalam satu cluster. Kita akan melakukan penggabungan berdasarkan tiga metode linkage: *Single Linkage*, *Complete Linkage*, dan *Average Linkage*.

AHC memiliki tiga metode penggabungan cluster:

- **Single Linkage (jarak minimum antara dua cluster)**

Definisi: Jarak antara dua cluster adalah jarak terpendek antara titik mana pun dalam kedua cluster.

Formula:

$$d(C_i, C_j) = \min\{d(a, b) \mid a \in C_i, b \in C_j\}$$

Langkah-langkah penggabungan:

1. Gabungkan (A, B) → Cluster {A, B}, karena jarak minimum adalah 2.

Matriks jarak baru (jarak minimum dengan {A, B} diambil dari A atau B):

	{A, B}	C	D	E
{A, B}	0	4	8	11
C	4	0	4	7
D	8	4	0	3
E	11	7	3	0

2. Gabungkan (C, D) → Cluster {C, D}, karena jarak minimum berikutnya adalah 4.

Matriks jarak baru:

	{A, B}	{C, D}	E
{A, B}	0	4	11
{C, D}	4	0	3
E	11	3	0

3. Gabungkan ({A, B}, {C, D}) → Cluster {A, B, C, D}, karena jarak minimum berikutnya adalah 4.

Matriks jarak baru:

	{A, B, C, D}	E
{A, B, C, D}	0	3
E	3	0

4. Gabungkan ({A, B, C, D}, E) → Semua dalam satu cluster, karena jarak terakhir adalah 3.

- **Complete Linkage (jarak maksimum antara dua cluster)**

Definisi: Jarak antar dua cluster ditentukan oleh jarak maksimum antara elemen-elemen dalam kedua cluster.

Formula:

$$d(C_i, C_j) = \max\{d(a, b) \mid a \in C_i, b \in C_j\}$$

Langkah-langkah penggabungan:

1. Gabungkan (A, B) → Cluster {A, B}, karena jarak minimum adalah 2.

Matriks jarak baru:

	{A, B}	C	D	E
{A, B}	0	6	10	13
C	6	0	4	7
D	10	4	0	3
E	13	7	3	0

2. Gabungkan (C, D) → Cluster {C, D}, karena jarak minimum berikutnya adalah 4.

Matriks jarak baru:

	{A, B}	{C, D}	E
{A, B}	0	6	13
{C, D}	6	0	7
E	13	7	0

3. Gabungkan ({A, B}, {C, D}) → Cluster {A, B, C, D}, karena jarak maksimum berikutnya adalah 6.

Matriks jarak baru:

	{A, B, C, D}	E
{A, B, C, D}	0	13
E	13	0

4. Gabungkan ({A, B, C, D}, E) → Semua dalam satu cluster, karena jarak terakhir adalah 13.

- **Average Linkage (rata-rata jarak antara elemen-elemen dalam dua cluster)**

Definisi: Jarak antar dua cluster ditentukan oleh rata-rata dari semua jarak antar elemen dalam kedua cluster.

- **Formula:**

$$d(C_i, C_j) = \frac{1}{|C_i| \cdot |C_j|} \sum_{a \in C_i} \sum_{b \in C_j} d(a, b)$$

Langkah-langkah Penggabungan

1. Gabungkan (A, B) → Cluster {A, B}, karena rata-rata jarak adalah 2
2. Gabungkan (C, D) → Cluster {C, D}, karena rata-rata jarak adalah 4.
3. Gabungkan ({A, B}, C) → Cluster {A, B, C}, dengan rata-rata 5.3.
4. Gabungkan ({A, B, C}, D) → Cluster {A, B, C, D}, dengan rata-rata 7.6.
5. Gabungkan ({A, B, C, D}, E) → Semua dalam satu cluster, dengan rata-rata 9.2.

Kode Program 8.2. Agglomerative Hierarchical Clustering.

No	Kode Program
1	import numpy as np
2	import scipy.cluster.hierarchy as sch
3	import matplotlib.pyplot as plt
4	from scipy.spatial.distance import pdist
5	# Dataset: Koordinat titik (X, Y)
6	data = np.array([
7	[1, 2], # A
8	[2, 3], # B
9	[3, 6], # C
10	[5, 8], # D
11	[8, 8] # E

```

12 ] )


13 # Menghitung matriks jarak menggunakan jarak Manhattan (Cityblock)
14 distance_matrix = pdist(data, metric='cityblock')

15 # Metode Linkage yang digunakan
16 linkage_methods = ['single', 'complete', 'average']
17 linkage_titles = ['Single Linkage', 'Complete Linkage', 'Average
18 Linkage']

19 # Visualisasi dendrogram untuk setiap metode linkage
20 plt.figure(figsize=(15, 5))

21 for i, method in enumerate(linkage_methods):
22     plt.subplot(1, 3, i + 1)
23     linked = sch.linkage(distance_matrix, method=method)
24     sch.dendrogram(linked, labels=["A", "B", "C", "D", "E"])
25     plt.title(f"Dendrogram - {linkage_titles[i]}")
26
27 plt.tight_layout()
28 plt.show()

```



Setelah menjalankan kode di atas, akan muncul **tiga dendrogram** yang menunjukkan bagaimana data dikelompokkan dalam **hierarchical clustering** dengan metode **Single Linkage, Complete Linkage, dan Average Linkage**, menggunakan **jarak Manhattan** sebagai ukuran kedekatan antar titik.

- **Single Linkage (Minimum Linkage)**
Pada dendrogram **Single Linkage**, dua titik dengan **jarak Manhattan terkecil** digabungkan terlebih dahulu. Dalam hal ini, **titik A dan B** adalah pasangan pertama yang dikelompokkan karena jarak antar mereka adalah **2**, yang merupakan jarak terkecil dalam matriks jarak Manhattan. Selanjutnya, titik **C dan D** digabungkan, karena mereka memiliki jarak **4** yang merupakan jarak terkecil berikutnya setelah pasangan pertama terbentuk. Proses ini berlanjut hingga semua titik tergabung menjadi satu cluster besar. Dendrogram yang dihasilkan cenderung **memiliki rantai panjang (chaining effect)**, di mana titik-titik yang dekat satu sama lain terus ditambahkan secara bertahap, sehingga struktur dendrogram tampak lebih melebar ke samping daripada bercabang dengan jelas.
- **Complete Linkage (Maximum Linkage)**
Pada dendrogram **Complete Linkage**, penggabungan cluster dilakukan berdasarkan **jarak maksimal** antar elemen dalam dua cluster yang akan digabungkan. Hal ini menyebabkan cluster yang terbentuk lebih **kompak dan seimbang** dibandingkan dengan Single Linkage. Pada awalnya, pasangan **A dan B** tetap digabungkan terlebih dahulu karena memiliki jarak minimum, tetapi setelah itu, penggabungan antar cluster lebih mempertimbangkan titik dengan jarak maksimum di antara mereka. Akibatnya, Complete Linkage cenderung menghasilkan **cluster dengan ukuran lebih seragam**, dan tidak terlalu dipengaruhi oleh efek rantai panjang seperti pada Single Linkage.
- **Average Linkage (Mean Linkage)**
Dendrogram untuk **Average Linkage** menunjukkan hasil yang merupakan kompromi antara Single Linkage dan Complete Linkage. Dalam metode ini, jarak antar dua cluster dihitung sebagai

rata-rata dari semua jarak antar elemen-elemen di kedua cluster. Proses penggabungan mengikuti pola di mana pasangan **A dan B** kembali menjadi yang pertama tergabung, diikuti oleh pasangan lain berdasarkan nilai rata-rata jarak mereka. Average Linkage menghasilkan **struktur dendrogram yang lebih seimbang dibandingkan dengan Single Linkage**, namun tidak seketat Complete Linkage dalam menjaga ukuran cluster yang kompak.

C. TUGAS/LATIHAN SOAL

Dalam tugas ini, Anda akan menerapkan Metode Clustering Hierarki menggunakan jarak Manhattan (Cityblock) untuk mengelompokkan beberapa kota di Jawa Timur berdasarkan koordinat latitude dan longitude. Anda akan melakukan perhitungan manual dan implementasi menggunakan Python untuk membandingkan hasil dari metode Single Linkage, Complete Linkage, dan Average Linkage.

1. Hitung matriks jarak Manhattan antar kota berikut:
 - Surabaya (-7.2504, 112.7688)
 - Malang (-7.9666, 112.6326)
 - Kediri (-7.8162, 112.0111)
 - Madiun (-7.6298, 111.5233)
 - Jember (-8.1724, 113.6879)
2. Berdasarkan matriks jarak yang dihitung, lakukan clustering manual menggunakan metode berikut:
 - a. Single Linkage (Jarak Minimum)
 - b. Complete Linkage (Jarak Maksimum)
 - c. Average Linkage (Rata-rata Jarak antar Titik dalam Cluster)
3. Gunakan Python untuk menghitung matriks jarak Manhattan dan menampilkan dendrogram clustering hierarki menggunakan ketiga metode di atas dan bandingkan hasil dari metode Single Linkage, Complete Linkage, dan Average Linkage.
4. Bandingkan hasil perhitungan manual dengan hasil dendrogram yang dihasilkan oleh Python dan Berikan kesimpulan tentang perbedaan hasil dari masing-masing metode.