

PERTEMUAN KE-9: METODE CLUSTERING DENSITY


A. TUJUAN

Setelah menempuh praktikum ini diharapkan mahasiswa mampu

1. menjelaskan cara kerja dari metode Density
2. membuat program metode Density dengan menggunakan Bahasa Pemrograman Python.
3. menggunakan metode Density untuk analisis cluster.

B. MATERI

DBSCAN (*Density Based Spatial Clustering of Applications with Noise*) merupakan suatu algoritma clustering yang didasarkan pada intuisi cerdas yang dapat menyelesaikan masalah yang paling sulit sekalipun. DBSCAN adalah algoritma pengelompokan yang didasarkan pada kepadatan (density) data. DBSCAN sering diterapkan pada data yang banyak mengandung noise, hal ini dikarenakan DBSCAN tidak akan memasukkan data yang dianggap noise kedalam cluster manapun. Algoritma ini memiliki gagasan bahwa cluster itu memiliki kepadatan yang tinggi, sehingga untuk mulai menjelajahi ruang data pada setiap arah dan menandai batas cluster ketika kepadatan berkurang hal-hal tersebut harus dilakukan dengan efisien. Jika pada area ruang data kerapatan titiknya tidak mencukupi, maka hanya akan dianggap kosong, dan semua titik di sana akan dianggap noise atau outlier, yaitu titik yang ditandai dengan nilai yang tidak biasa.



Gambar 9.1. Ilustrasi dari Istilah dalam DBScan Algorithm.

Konsep kepadatan yang dimaksud dalam DBSCAN adalah banyaknya data (minPts) yang berada dalam radius Eps (ϵ) dari setiap data. Konsep kepadatan seperti ini menghasilkan tiga macam status dari setiap data, yaitu inti (core), batas (border), dan noise. Eps merupakan jarak maksimal antara dua data dalam satu cluster yang diizinkan, dan minimum points (minPts) adalah banyaknya data minimal dalam jarak epsilon agar terbentuk suatu cluster. Selain epsilon dan MinPts ada beberapa terminologi lain dalam metode DBSCAN yaitu :

- a. directly density-reachable yaitu observasi q berhubungan langsung dengan p, jika p adalah core point dan q merupakan tetangga dari p dalam jangkauan epsilon.
- b. density-reachable yaitu observasi q dan x dalam satu cluster namun x bukan tetangga dari q dalam jangkauan epsilon.
- c. core point. Core point merupakan observasi yang memiliki jumlah tetangga lebih dari sama dengan dari MinPts pada jangkauan Eps.
- d. border point. Border point memiliki tetangga lebih sedikit dari Minpts namun ia merupakan tetangga dari core point.
- e. outlier/noise point. Observasi yang bukan border points atau core points.

Namun dengan kelebihan yang bisa menangani masalah-masalah sulit dibanding algoritma lain, DBSCAN menjadi lebih kompleks dan membutuhkan banyak waktu yang berjalan dibanding K-Means. Tapi di sisi lain DBSCAN memudahkan kita untuk tidak perlu memberikan suatu k yaitu jumlah dari cluster yang diprediksi karena algoritma ini akan mencari sendiri. Adapun kelebihan lain dari DBSCAN adalah

- a. Tidak seperti K-means, DBSCAN tidak meminta kepada user untuk memasukkan nilai berapa banyak cluster yang akan dibuat

- b. DBSCAN dapat membuat cluster dengan beragam bentuk, tidak harus berbentuk circle (lingkaran).
- c. DBSCAN dapat membedakan data mana yang outliers.

Cara kerja Algoritma DBSCAN

Tujuan dari algoritma DBSCAN ini adalah untuk mengidentifikasi high-density area yang dapat diukur dengan jumlah objek yang mendekati titik tertentu. DBSCAN tidak terlepas dari 2 parameter penting yang diperlukan, yakni bernama epsilon ("eps") dan juga minimum points ("MinPts"). Parameter epsilon berfungsi untuk menentukan radius antara titik x terhadap sekelilingnya. Sedangkan MinPts menentukan jumlah minimum anggota yang ada di sekitar dalam radius epsilon ("eps"). Setiap titik x dalam dataset, dengan jumlah neighbour lebih dari atau sama dengan MinPts, maka ini akan ditandai sebagai titik inti (core points). Apabila jumlah neighbour kurang dari MinPts, tetapi ia termasuk dalam lingkungan epsilon dari beberapa titik inti z , jika suatu titik bukanlah inti atau titik x , maka itu disebut titik noise atau outlier. Metode jarak yang digunakan dalam DBSCAN adalah jarak Euclidian. Secara sederhana cara kerja DBSCAN adalah sebagai berikut :

- a. Tentukan nilai minPts dan epsilon (eps) yang akan digunakan.
- b. Pilih data awal "p" secara acak.
- c. Hitung jarak antara data "p" terhadap semua data menggunakan Euclidian distance.
- d. Ambil semua amatan yang density-reachable dengan amatan "p".
- e. Jika amatan yang memenuhi nilai epsilon lebih dari jumlah minimal amatan dalam satu gerombol maka amatan "p" dikategorikan sebagai core points dan gerombol terbentuk.
- f. Jika amatan "p" adalah border points dan tidak ada amatan yang density-reachable dengan amatan "p", maka lanjutkan pada amatan lainnya.
- g. Ulangi langkah 3 sampai 6 hingga semua amatan diproses.

Contoh 9.1

Sebuah pusat perbelanjaan ingin melakukan segmentasi pelanggan berdasarkan Annual Income dan Spending Score agar dapat merancang strategi pemasaran yang lebih tepat sasaran. Anda diminta untuk menganalisis data pelanggan dengan menggunakan dua metode clustering yang berbeda, yaitu DBSCAN dan K-Means, serta mengevaluasi performanya.

Jawaban

Kode Program 9.1. Program perbandingan metode DB-Scan dan K-means

No	Kode Program
1	import numpy as np
2	import pandas as pd
3	import matplotlib.pyplot as plt
4	import seaborn as sns
5	from sklearn.preprocessing import StandardScaler
6	from sklearn.cluster import DBSCAN, KMeans
7	from sklearn.metrics import silhouette_score
8	from scipy.spatial.distance import cdist
9	# Load dataset
10	df = pd.read_csv("Mall_Customers.csv")
11	# Pilih fitur untuk clustering (Annual Income & Spending Score)
12	X = df.iloc[:, [3, 4]].values
13	# Normalisasi data
14	scaler = StandardScaler()
15	X_scaled = scaler.fit_transform(X)
16	
17	# ===== DBSCAN OPTIMIZATION =====
18	eps_values = np.arange(0.2, 1.2, 0.1)
19	min_samples_values = range(3, 10)
20	best_eps, best_min_samples, best_silhouette = None, None, -1
21	for eps in eps_values:
22	for min_samples in min_samples_values:
23	dbscan = DBSCAN(eps=eps, min_samples=min_samples)
24	labels = dbscan.fit_predict(X_scaled)
25	n_clusters = len(set(labels)) - (1 if -1 in labels else 0)
26	if n_clusters > 1: # Hitung silhouette score jika minimal ada 2
27	cluster
28	filtered_labels = labels[labels != -1]
29	filtered_data = X_scaled[labels != -1]


```

30         sil_score = silhouette_score(filtered_data, filtered_labels)
31         if sil_score > best_silhouette:
32             best_eps, best_min_samples, best_silhouette = eps,
33 min_samples, sil_score
34 # Train DBSCAN dengan parameter terbaik
35 dbscan_best = DBSCAN(eps=best_eps, min_samples=best_min_samples)
36 dbscan_labels = dbscan_best.fit_predict(X_scaled)
37 # ===== K-MEANS OPTIMIZATION =====
38 distortions, silhouette_scores = [], []
39 K_range = range(2, 11)
40 for k in K_range:
41     kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
42     kmeans.fit(X_scaled)
43     distortions.append(sum(np.min(cdist(X_scaled,
44 kmeans.cluster_centers_, 'euclidean'), axis=1)) / X_scaled.shape[0])
45     silhouette_scores.append(silhouette_score(X_scaled,
46 kmeans.labels_))
47 # Menentukan K optimal berdasarkan Elbow Method
48 best_k = K_range[np.argmax(silhouette_scores)]
49 # Train K-Means dengan jumlah cluster terbaik
50 kmeans_best = KMeans(n_clusters=best_k, random_state=42, n_init=10)
51 kmeans_labels = kmeans_best.fit_predict(X_scaled)
52 # ===== PRINT HASIL ANALISIS =====
53 print(f"=== DBSCAN RESULTS ===")
54 print(f"Best Epsilon: {best_eps}")
55 print(f"Best Min Samples: {best_min_samples}")
56 print(f"Best Silhouette Score: {best_silhouette:.4f}")
57 print(f"Number of Clusters (DBSCAN): {len(set(dbscan_labels)) - (1 if -
58 1 in dbscan_labels else 0)}")
59 print("\n=== K-MEANS RESULTS ===")
60 print(f"Optimal Number of Clusters (Elbow Method): {best_k}")
61 print(f"Silhouette Score (K-Means): {max(silhouette_scores):.4f}")
62
63 # ===== VISUALIZATION =====
64 fig, axes = plt.subplots(1, 3, figsize=(18, 5))
65 # Elbow Method plot
66 axes[0].plot(K_range, distortions, marker='o')
67 axes[0].set_xlabel("Number of Clusters (K)")
68 axes[0].set_ylabel("Distortion")
69 axes[0].set_title("Elbow Method for Optimal K")
70 # DBSCAN plot
71 df["DBSCAN_Cluster"] = dbscan_labels
72 sns.scatterplot(x=df["Annual Income (k$)"], y=df["Spending Score (1-
73 100)"], hue=df["DBSCAN_Cluster"], palette="tab10", s=100, ax=axes[1])
74 axes[1].set_title("DBSCAN Clustering")
75 axes[1].set_xlabel("Annual Income (k$)")
76 axes[1].set_ylabel("Spending Score (1-100)")
77 # K-Means plot
78 df["KMeans_Cluster"] = kmeans_labels
79 sns.scatterplot(x=df["Annual Income (k$)"], y=df["Spending Score (1-
80 100)"], hue=df["KMeans_Cluster"], palette="tab10", s=100, ax=axes[2])
81 axes[2].set_title("K-Means Clustering")
82 axes[2].set_xlabel("Annual Income (k$)")
83 axes[2].set_ylabel("Spending Score (1-100)")
84 plt.show()

```

Keluaran dari program diatas adalah

=== DBSCAN RESULTS ===

Best Epsilon: 0.30000000000000004

Best Min Samples: 7


Best Silhouette Score: 0.6452

Number of Clusters (DBSCAN): 4

=== K-MEANS RESULTS ===

Optimal Number of Clusters (Elbow Method): 5

Silhouette Score (K-Means): 0.5547



Gambar 9.1. Perbandingan K-means dan DB-Scan

DBSCAN berhasil membentuk 4 cluster dengan Silhouette Score yang cukup tinggi (0.6452), menunjukkan bahwa hasil clustering cukup baik. Nilai $\text{eps} = 0.3$ dan $\text{min_samples} = 7$ adalah kombinasi terbaik, artinya DBSCAN mampu mendeteksi struktur data dengan baik pada parameter ini. DBSCAN cocok untuk data dengan pola non-linier, terutama jika terdapat kelompok dengan bentuk tidak teratur.

Optimal Number of Clusters (K) berdasarkan Elbow Method untuk metode K-means adalah 5. Silhouette Score adalah 0.5547. K-Means memilih 5 cluster sebagai jumlah optimal, tetapi Silhouette Score lebih rendah dibandingkan DBSCAN (0.5547 vs. 0.6452). Silhouette Score yang lebih rendah menunjukkan bahwa beberapa titik data mungkin berada di batas antara cluster (kurang terpisah dengan baik). K-Means cocok untuk data berbentuk bola (spherical clusters), sehingga jika data memiliki distribusi yang lebih kompleks, performanya bisa lebih rendah dibandingkan DBSCAN. DBSCAN lebih baik dalam kasus ini karena memiliki Silhouette Score lebih tinggi (0.6452 vs. 0.5547) dan tidak terpaksa membentuk 5 cluster seperti K-Means. Jika data memiliki banyak noise atau pola yang tidak teratur, DBSCAN lebih unggul dibandingkan K-Means.

Dari hasil clustering menggunakan DBSCAN, kita dapat melihat bahwa pelanggan telah dibagi menjadi 4 cluster utama (0, 1, 2, 3) serta outlier (-1) berdasarkan Annual Income (Pendapatan Tahunan) dan Spending Score (Skor Pengeluaran). Cluster -1 (Outliers - warna biru) merupakan titik-titik ini dianggap outlier/noise oleh DBSCAN. Kemungkinan besar ini adalah pelanggan yang tidak masuk dalam pola yang jelas. Mereka bisa memiliki pola pembelian yang sangat unik atau berbeda dari mayoritas pelanggan.

Cluster 0 (Warna hijau, tengah) merupakan pelanggan dengan pendapatan tahunan sekitar \$40k - \$70k. Spending Score di sekitar 40-60. Ini adalah pelanggan dengan pendapatan menengah dan pengeluaran menengah—kemungkinan pelanggan yang stabil dalam kebiasaan belanja mereka.

Cluster 1 (Warna oranye, kiri atas) merupakan pelanggan dengan pendapatan rendah (~\$20k-\$30k), tetapi Spending Score tinggi (~60-80). Pelanggan ini memiliki daya beli tinggi meskipun berpenghasilan rendah, kemungkinan kelompok remaja atau pelanggan yang mengutamakan pengeluaran untuk hiburan dan belanja. Cluster 2 (Warna merah, kanan atas) merupakan pelanggan dengan pendapatan tinggi (~\$70k-\$100k), Spending Score tinggi (~80-100). Ini adalah pelanggan VIP atau high spenders, yaitu orang dengan penghasilan tinggi yang suka menghabiskan uang untuk belanja. Kelompok ini penting bagi bisnis karena memiliki daya beli yang tinggi.

Cluster 3 (Warna ungu, kanan bawah) adalah pelanggan dengan pendapatan tinggi (~\$80k-\$120k), tetapi Spending Score rendah (~20-40). Pelanggan ini memiliki penghasilan besar, tetapi mereka tidak menghabiskan banyak uang di mall. Bisa jadi mereka lebih memilih menabung, berinvestasi, atau berbelanja di tempat lain.

Pelanggan dalam cluster 2 (merah) adalah target terbaik untuk strategi pemasaran premium, seperti diskon eksklusif, keanggotaan VIP, dan layanan premium. Pelanggan dalam cluster 1 (oranye) bisa menjadi target promosi produk dengan harga terjangkau karena mereka memiliki Spending Score tinggi meskipun pendapatan rendah. Cluster 3 (ungu) membutuhkan strategi khusus untuk meningkatkan pengeluaran mereka, misalnya dengan loyalty program atau promosi eksklusif untuk menarik mereka agar lebih sering berbelanja. Outlier (-1) bisa diabaikan atau dianalisis lebih lanjut untuk memahami apakah ada pola unik dalam perilaku mereka.

C. TUGAS/LATIHAN SOAL

1. Bandingkan hasil dari contoh 9.1 dengan metode hierarki clustering.