

PERTEMUAN KE-13: METODE KLASIFIKASI NAIVE BAYES

A. TUJUAN

Setelah menempuh praktikum ini diharapkan mahasiswa mampu

1. Memahami konsep dasar dari **Naive Bayes** dan asumsi yang mendasari model ini.
2. Mampu mengimplementasikan **Naive Bayes** untuk masalah klasifikasi.
3. Menghitung probabilitas posterior menggunakan Teorema Bayes.
4. Mengevaluasi kinerja model menggunakan metrik seperti **accuracy**, **precision**, **recall**, dan **F1-score**.

B. MATERI

Naïve Bayes Classifier merupakan sebuah metoda klasifikasi yang berakar pada teorema Bayes . Metode pengklasifikasian dengan menggunakan metode probabilitas dan statistik yang dikemukakan oleh ilmuwan Inggris Thomas Bayes , yaitu memprediksi peluang di masa depan berdasarkan pengalaman di masa sebelumnya sehingga dikenal sebagai Teorema Bayes . Ciri utama dari Naïve Bayes Classifier ini adalah asumsi yang sangat kuat (naïf) akan independensi dari masing-masing kondisi / kejadian.

Menurut Olson Delen (2008) menjelaskan Naïve Bayes untuk setiap kelas keputusan, menghitung probabilitas dengan syarat bahwa kelas keputusan adalah benar, mengingat vektor informasi obyek. Algoritma ini mengasumsikan bahwa atribut obyek adalah independen. Probabilitas yang terlibat dalam memproduksi perkiraan akhir dihitung sebagai jumlah frekuensi dari " master " tabel keputusan.

Naive Bayes Classifier bekerja sangat baik dibandingkan dengan model classifier lainnya. Hal ini dibuktikan oleh Xhemali , Hinde Stone dalam jurnalnya "Naïve Bayes vs. Decision Trees vs. Neural Networks in the Classification of Training Web Pages" mengatakan bahwa "Naïve Bayes Classifier memiliki tingkat akurasi yang lebih baik dibandingkan model classifier lainnya".

Keuntungan penggunaan Naive Bayes Classifier adalah bahwa metoda ini hanya membutuhkan jumlah data pelatihan (*training data*) yang kecil untuk menentukan estimasi parameter yang diperlukan dalam proses pengklasifikasian. Karena yang diasumsikan sebagai *variable independent*, maka hanya varians dari suatu *variable* dalam sebuah kelas yang dibutuhkan untuk menentukan klasifikasi, bukan keseluruhan dari matriks kovarians.

Beberapa kegunaan Naïve Bayes adalah untuk mengklasifikasikan dokumen teks seperti teks berita ataupun teks akademis, sebagai metode machine learning yang menggunakan probabilitas, untuk membuat diagnosis medis secara otomatis, mendeteksi atau menyaring spam. Sedangkan beberapa kelebihan dari Naïve Bayes adalah bisa dipakai untuk data kuantitatif maupun kualitatif, tidak memerlukan jumlah data yang banyak, tidak perlu melakukan data training yang banyak, jika ada nilai yang hilang, maka bisa diabaikan dalam perhitungan, perhitungannya cepat dan efisien, mudah dipahami, mudah dibuat pengklasifikasian dokumen bisa dipersonalisasi, disesuaikan dengan kebutuhan setiap orang, Jika digunakan dalaam bahasa pemrograman, code-nya sederhana, bisa digunakan untuk klasifikasi masalah biner ataupun multiclass. Beberapa kekurangan dari Naïve Bayes adalah

1. Apabila probabilitas kondisionalnya bernilai nol, maka probabilitas prediksi juga akan bernilai nol
2. Asumsi bahwa masing-masing variabel independen membuat berkurangnya akurasi, karena biasanya ada korelasi antara variabel yang satu dengan variabel yang lain
3. Keakuratannya tidak bisa diukur menggunakan satu probabilitas saja. Butuh bukti-bukti lain untuk membuktikannya.
4. Untuk membuat keputusan, diperlukan pengetahuan awal atau pengetahuan mengenai masa sebelumnya. Keberhasilannya sangat bergantung pada pengetahuan awal tersebut Banyak celah yang bisa mengurangi efektivitasnya
5. Dirancang untuk mendeteksi kata-kata saja, tidak bisa berupa gambar.

Persamaan Teorema Bayes

Tabel Frekuensi		Play Golf	
		Yes	No
Out Look	Sunny	3	2
	Overcast	4	0
	Rainy	2	3

Tabel Likelihood		Play Golf		
		Yes	No	
Out Look	Sunny	$P(x c) = P(\text{sunny} \text{Yes}) = 3/9$	2/5	$P(x) = P(\text{sunny}) = 5/14$
	Overcast	4/9	0/5	4/14
	Rainy	2/9	3/5	5/14
		$P(\text{yes}) = 9/14$	5/14	

$$P(c|x) = P(\text{Yes} | \text{sunny}) = 0,33 \times 0,64 / 0,36 = 0,6$$

Berikut ini adalah rumus dari Bayes

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$

dimana x adalah data dengan class yang belum diketahui, c adalah Hipotesis data merupakan suatu class spesifik, $P(c|x)$ adalah Probabilitas hipotesis berdasar kondisi (posteriori probability), $P(c)$ adalah Probabilitas hipotesis (prior probability), $P(x|c)$ adalah Probabilitas berdasarkan kondisi pada hipotesis dan $P(x)$ adalah Probabilitas x .

Rumus diatas menjelaskan bahwa peluang masuknya sampel karakteristik tertentu dalam kelas C (Posterior) adalah peluang munculnya kelas C (sebelum masuknya sampel tersebut, seringkali disebut prior), dikali dengan peluang kemunculan karakteristik karakteristik sampel pada kelas C (disebut juga likelihood), dibagi dengan peluang kemunculan karakteristik sampel secara global (disebut juga evidence). Karena itu, rumus diatas dapat pula ditulis sebagai berikut :

$$\text{posterior} = \frac{\text{prior} \times \text{likelihood}}{\text{evidence}}$$

Nilai Evidence selalu tetap untuk setiap kelas pada satu sampel. Nilai dari posterior tersebut nantinya akan dibandingkan dengan nilai nilai posterior kelas lainnya untuk menentukan ke kelas apa suatu sampel akan diklasifikasikan. Penjabaran lebih lanjut rumus Bayes tersebut dilakukan dengan menjabarkan $(c/x_1, \dots, x_n)$ menggunakan aturan perkalian sebagai berikut :

$$\text{posterior} = \frac{\text{prior} \times \text{likelihood}}{\text{evidence}}$$

$$\begin{aligned}
 P(C | X_1, X_2, \dots, X_n) &= P(C) \times P(X_1, X_2, \dots, X_n | C) \\
 &= P(C) \times P(X_1 | C) \times P(X_2, \dots, X_n | C) \\
 &= P(C) \times P(X_1 | C) \times P(X_2 | C, X_1) \times P(X_3, \dots, X_n | C) \\
 &= P(C) \times P(X_1 | C) \times P(X_2 | C, X_1) \times P(X_3 | C, X_1, X_2) \times P(X_3, \dots, X_n | C)
 \end{aligned}$$

Dapat dilihat bahwa hasil penjabaran tersebut menyebabkan semakin banyak dan semakin kompleksnya faktor faktor syarat yang mempengaruhi nilai probabilitas, yang hampir mustahil untuk dianalisa satu

persatu. Akibatnya, perhitungan tersebut menjadi sulit untuk dilakukan. Disinilah digunakan asumsi independensi yang sangat tinggi (naif), bahwa masing masing petunjuk saling bebas (independen) satu sama lain. Dengan asumsi tersebut, maka berlaku suatu kesamaan sebagai berikut:

$$P(C | X_1, X_2, \dots, X_n) = P(C) \times \prod_{i=1}^n P(X_i | C)$$

$$P(C | X) = P(X_{1i} | C)P(X_{2i} | C) \dots P(X_{ni} | C)$$

Persamaan diatas merupakan model dari **Teorema Naive Bayes** yang selanjutnya akan digunakan dalam proses klasifikasi. Untuk klasifikasi dengan data kontinyu digunakan rumus Densitas Gauss : sebagai berikut

$$P(X_i = x_i | Y_i = y_i) = \frac{1}{\sqrt{2\pi\sigma_{ij}}} e^{-\frac{(x_i - \mu_{ij})^2}{2\sigma_{ij}^2}}$$

dimana P adalah Peluang, X_i adalah Atribut ke i , x_i adalah Nilai atribut ke i , Y adalah Kelas yang dicari, y_i adalah Sub kelas Y yang dicari, μ adalah Mean, menyatakan rata rata dari seluruh atribut dan σ adalah Deviasi standar, menyatakan varian dari seluruh atribut

Mean didefinisikan oleh

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Deviasi Standar didefinisikan oleh

$$\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$

Contoh 13.3

Contoh Kasus: Klasifikasi Iris Dataset

Iris dataset adalah dataset yang berisi informasi tentang panjang dan lebar sepal dan petal dari tiga jenis bunga iris (Setosa, Versicolor, Virginica). Tujuan dari model klasifikasi ini adalah untuk memprediksi jenis bunga iris berdasarkan panjang dan lebar sepal dan petal.

Pada implementasi **Decision Tree** menggunakan **Iris Dataset**, langkah pertama yang harus dilakukan adalah **praproses data**, di mana kita memisahkan fitur (X) dan label (y). Fitur dalam dataset ini meliputi panjang sepal (sepal length), lebar sepal (sepal width), panjang petal (petal length), dan lebar petal (petal width), sementara labelnya terdiri dari tiga kelas bunga iris, yaitu Setosa, Versicolor, dan Virginica. Setelah memisahkan fitur dan label, data kemudian dibagi menjadi dua bagian: data pelatihan (training) untuk membangun model dan data uji (test) untuk mengevaluasi performa model.

Selanjutnya, langkah kedua adalah **membangun model Decision Tree**, yang dapat menggunakan algoritma **ID3** atau **CART**. Dalam hal ini, metrik pembelahan yang digunakan bisa berupa **information gain** (untuk ID3) atau **Gini Impurity** (untuk CART). Kedua metrik ini berfungsi untuk memilih atribut terbaik yang akan membagi dataset pada setiap simpul pohon berdasarkan seberapa besar pengaruhnya terhadap pembagian data.

Setelah model terbentuk, tahap berikutnya adalah **evaluasi model**. Evaluasi dilakukan dengan mengukur kinerja model menggunakan metrik **accuracy**, **precision**, **recall**, dan **F1-score**. Accuracy mengukur seberapa sering model benar dalam melakukan prediksi, sementara precision dan recall memberikan gambaran lebih mendalam tentang bagaimana model mengidentifikasi masing-masing kelas. F1-score, yang merupakan rata-rata harmonis dari precision dan recall, digunakan untuk memberikan ukuran keseluruhan performa model, terutama saat kelas data tidak seimbang.

Jawaban

Kode Program 12.12. Program Naïve Bayes

No	Kode Program
1	<code>from sklearn.feature_extraction.text import CountVectorizer</code>
2	<code>from sklearn.model_selection import train_test_split</code>

```

3 from sklearn.naive_bayes import MultinomialNB
4 from sklearn.metrics import accuracy_score, classification_report,
5 confusion_matrix
6 # Contoh data email
7 emails = [
8     'free offer win cash now', 'urgent work opportunity', 'win a prize
9     now',
10    'meet the new colleague tomorrow', 'free vacation offers', 'work
11    assignment details'
12 ]
13 labels = ['spam', 'ham', 'spam', 'ham', 'spam', 'ham']
14 # Mengubah teks menjadi fitur numerik menggunakan CountVectorizer
15 vectorizer = CountVectorizer()
16 X = vectorizer.fit_transform(emails)
17 y = labels
18 # Pisahkan data menjadi training dan testing
19 X_train, X_test, y_train, y_test = train_test_split(X, y,
20 test_size=0.33, random_state=42)
21 # Bangun model Naive Bayes
22 nb = MultinomialNB()
23 nb.fit(X_train, y_train)
24 # Prediksi dengan data uji
25 y_pred = nb.predict(X_test)
26 # Evaluasi model
27 print("Accuracy:", accuracy_score(y_test, y_pred))
28 print("Classification Report:")
29 print(classification_report(y_test, y_pred))
40 print("Confusion Matrix:")
41 print(confusion_matrix(y_test, y_pred))

```

Hasil evaluasi model **Naive Bayes** pada dataset email dengan label **spam** dan **ham** menunjukkan bahwa model ini memiliki **accuracy 1.0**, yang berarti bahwa model berhasil melakukan prediksi dengan sempurna pada semua data uji. Berikut adalah analisis lebih detail berdasarkan **Classification Report** dan **Confusion Matrix**.

Classification Report:

- **Precision:** Precision untuk kedua kelas (**ham** dan **spam**) adalah 1.00, yang berarti bahwa setiap kali model memprediksi email sebagai spam atau ham, prediksi tersebut 100% benar. Tidak ada prediksi yang salah, baik untuk email spam maupun ham.
- **Recall:** Recall untuk kedua kelas juga 1.00, yang menunjukkan bahwa model berhasil mengidentifikasi semua email spam dan ham dengan benar. Tidak ada email yang terlewat atau salah diklasifikasikan ke dalam kelas yang berbeda.
- **F1-score:** F1-score juga bernilai 1.00 untuk kedua kelas, yang menunjukkan keseimbangan yang sempurna antara precision dan recall. F1-score adalah ukuran yang menggabungkan precision dan recall, dan nilai 1.00 menandakan bahwa model sangat baik dalam mengklasifikasikan email secara akurat tanpa kesalahan.
- **Support:** Support menunjukkan jumlah sampel untuk setiap kelas dalam data uji, di mana ada 1 email untuk kelas **ham** dan 1 email untuk kelas **spam**.
- **Macro Average:** Rata-rata untuk precision, recall, dan F1-score di seluruh kelas adalah 1.00, yang menunjukkan bahwa model bekerja sangat baik di kedua kelas secara merata.
- **Weighted Average:** Rata-rata berbobot untuk precision, recall, dan F1-score juga menunjukkan nilai 1.00, yang memperhitungkan jumlah sampel dari setiap kelas, dan ini mengonfirmasi bahwa model bekerja sempurna di seluruh data uji.

Confusion Matrix:

- **Confusion Matrix** menunjukkan hasil klasifikasi model. Di dalam matriks ini, nilai diagonal (1, 1) menunjukkan bahwa satu email ham dan satu email spam diprediksi dengan benar. Tidak ada nilai yang terdapat di luar diagonal, yang mengindikasikan bahwa tidak ada kesalahan klasifikasi.

```
Confusion Matrix:  
[[1 0]  
 [0 1]]
```

Di sini, baris pertama dan kolom pertama mewakili **ham**, sedangkan baris kedua dan kolom kedua mewakili **spam**. Nilai 1 pada posisi diagonal menunjukkan prediksi yang benar, sedangkan nilai 0 pada posisi non-diagonal menunjukkan tidak adanya kesalahan prediksi.

C. TUGAS/LATIHAN SOAL

1. **Pilih Dataset Teks:** Pilih salah satu dataset berikut:

- **SMS Spam Collection**
(<https://archive.ics.uci.edu/ml/datasets/sms+spam+collection>)
- **20 Newsgroups Dataset**
(<https://archive.ics.uci.edu/ml/datasets/Twenty+Newsgroups>)

2. **Praproses Data:**

- Lakukan tokenisasi dan representasi data teks menjadi fitur numerik menggunakan CountVectorizer atau TF-IDF.
- Pisahkan data menjadi data pelatihan dan data uji.

3. **Implementasi Naive Bayes:**

- Gunakan Multinomial Naive Bayes atau Bernoulli Naive Bayes (tergantung pada jenis data) untuk membangun model.

4. **Evaluasi Model:**

- Hitung accuracy, precision, recall, dan F1-score untuk mengevaluasi performa model.

5. **Analisis Hasil:**

- Analisis dan interpretasikan hasil confusion matrix dan metrik evaluasi lainnya.

PERTEMUAN KE-14: EVALUASI MODEL KLASIFIKASI

A. TUJUAN

Setelah menempuh praktikum ini diharapkan mahasiswa mampu

1. memahami cara kerja dari metode evaluasi untuk metode klasifikasi.
2. membuat program metode evaluasi untuk metode klasifikasi dengan menggunakan Bahasa Pemrograman Python.
3. mengevaluasi metode klasifikasi

B. MATERI

Pengukuran kinerja dari suatu model merupakan langkah penting dalam machine learning sehingga dapat menjadi pertimbangan untuk memilih model “terbaik”. Salah satu teknik yang dapat digunakan untuk